

SK네트웍스 Family AI과정 21기

데이터 전처리 인공지능 학습 결과서

산출물 단계	데이터 전처리
평가 산출물	인공지능 학습 결과서
제출 일자	2026.03.03.
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN21-FINAL-2Team.git
작성 팀원	전우영

목차

1. 프로젝트 개요
2. RAG용 모델
 - 2.1. Embedding 모델
 - 2.2. Reranking 모델
3. 응답 생성 모델
4. 데이터 전처리 단계 툴 및 모델

1. 프로젝트 개요

Triver(트리버)는 외국인 관광객들의 국내 여행 전 과정을 책임지는 LLM 기반 AI 여행 에이전트.

- 초개인화 추천 엔진: 사용자의 명시적인 요청뿐만 아니라 이미지, 과거 취향, 실시간 상황을 복합적으로 분석하여 사용자에게 딱 맞는 장소를 추천
- 장소 추천부터 코스 계획까지: 개별 장소 반환에서 나아가 사용자의 위치, 이동 수단 등을 종합적으로 분석하여 이동 효율을 극대화하는 알고리즘 기반 동선 설계
- 여행 계획과 예약 관리: 여행지 검색부터 여행 상품 예약까지 가능한 채팅 인터페이스, 여러 플랫폼에서 예약한 다양한 바우처를 저장해둘 수 있는 나만의 여행 지갑 제공

2. RAG용 모델

2.1. Embedding 모델

본 프로젝트는 텍스트 중심 질의와 이미지 기반 질의를 함께 처리해야 하므로, 단일 임베딩 모델이 아닌 이원화된 임베딩 전략을 취함.

텍스트 임베딩 BAAI/bge-m3	- BGE-M3는 Dense 임베딩뿐 아니라 Sparse 표현도 함께 다룰 수 있는 확장성 존재. 현재 서비스 파이프라인은 Dense 검색 중심으로 운영하고 있으나, 향후 Sparse 검색을 결합해도 품질 유지가 가능한지 추가 검증할 계획이므로 유용함 - 다국어 질의 대응 관점에서도 BGE-M3는 다국어 처리 범위가 넓은 편으로 알려져 있어(문헌/리포트 기준 약 100~170개 수준 언급), 한국어 중심 서비스에서 안정적인 선택지라고 판단
이미지 임베딩 clip-ViT-L-14	- CLIP은 텍스트와 이미지를 동일 벡터 공간으로 임베딩해, “이 문장과 이 이미지가 얼마나 어울리는가”를 기준으로 학습된 모델. - 덕분에 text-to-image, image-to-image 검색에는 강점

2.2. 모델별 역할 분리

- CLIP (clip-ViT-L-14)
 - 이미지 임베딩 생성
 - 텍스트를 이미지 임베딩 공간에 투영하여 text-to-image 검색 수행
 - 이미지 유사도 검색(image-to-image) 수행
- BGE-M3 (BAAI/bge-m3)
 - 한국어 질의 포함 텍스트 의미 검색(text-to-text) 담당
 - 장소 설명 문서(llm_text) 임베딩 및 검색 담당

2.3. CLIP 단일 모델 사용 계획에서 이원화

- 원인: 초기에는 CLIP 단일 모델로 통합하려 했으나, CLIP 모델은 영어로 학습 모델이다 보니 실제 검색 시나리오에서 한국어 텍스트 질의 정확도가 낮아지는 문제 확인. 특히 관광/맛집 도메인에서 한국어 표현에 대한 검색 일관성 저하
- 해결책: 텍스트 임베딩 모델과 이미지 임베딩 모델을 분리. 텍스트 의미 검색 정확도는 BGE-M3로 보완하고 이미지 관련 검색은 CLIP의 강점을 유지하는 하이브리드 구조 적용

2.4. Reranking 모델

현재 코드베이스에는 별도 Reranker가 적용되어 있지 않지만, 대신 **search_hybrid**에서 채널별 가중치를 적용하는 방식으로 1차 융합 점수 계산. 이는 구현 복잡도 대비 효과는 있으나, 문맥 수준 재정렬(정밀 re-ranking)이 부족하므로 향후 개선 여지 큼.

- text semantic: 가중치 1.0
- text-to-image: 가중치 0.5

- image visual: 가중치 1.0
- image emotional(BGE-M3): 가중치 0.8
- 다중 채널 동시 매칭 시 추가 boost 적용

2.5. RAG 파이프라인 구조

2.5.1. 오프라인 인덱싱

- 원천 관광 데이터 수집
- LLM 기반 설명 텍스트 생성
- Qdrant 적재
 - places 컬렉션: 텍스트 벡터
 - photos 컬렉션: 이미지 벡터

2.5.2. 온라인 질의 처리

1. 사용자 입력(텍스트/이미지/위치) 수신
2. LangGraph 기반 에이전트 플로우 실행 (intent -> planner -> retriever -> executor)
3. Retriever에서 하이브리드 검색 수행
 - 이미지 설명문 기반 감성 검색(GPT-4o-mini -> BGE-M3)
 - 텍스트 의미 검색(BGE-M3)
 - text-to-image 검색(CLIP text)
4. image-to-image 검색(CLIP vision)
5. 후보 장소를 통합/정렬 후 최종 컨텍스트 구성
6. 생성 모델이 컨텍스트 기반 답변 생성

3. 응답 생성 모델

다만, 현재 단계에서는 생성 모델 간의 정식 비교 실험(A/B, 블라인드 평가)이 충분히 수행되지 않아, 최적 모델 확보보다는 운영 가능한 기본 모델 선정 단계에 가까움

응답 생성 gpt-4o-mini	• GPT-3.5 Turbo 대비 비용이 더 낮아 대량 배치 작업에 유리, GPT-4o 대비 추론 속도가 빨라 실사용 응답성과 전처리 처리량 확보에 유리 • 다수 장소 후보를 빠르게 조회·생성해야 하므로, 최고 성능 단일 지표보다 처리량(throughput)과 비용 효율을 우선으로 삼아 채택
------------------------------------	--

4. 데이터 전처리 단계 툴 및 모델

4.1. Tavily Search (미채택)

초기에는 벡터DB에 적재할 텍스트를 보강하기 위해 Tavily 실시간 검색 결과를 활용

시도 과정	1. 장소명/주소/카테고리 기반 쿼리 생성 2. 검색 결과를 점수화/필터링 3. 필터링한 실시간 컨텍스트를 LLM 프롬프트에 주입해 설명문 생성
--------------	--

미채택 사유	• 검색 결과 품질이 질의별로 불안정함. 근거가 약한 검색 결과가 들어오면 설명문에 사실성이 낮은 문장이 섞이는 것이 가장 큰 문제 • 실시간 검색 특성상 재현성(동일 입력=동일 출력) 관리가 어려움
---------------	--

4.2. GPT-4o-mini (채택)

최종적으로 전처리 과정에서 장소 데이터를 보강하는 데에는 GPT 모델을 사용

적용 방식	1. 입력 JSON의 구조화 필드를 기반으로 장소 설명문 생성 2. 결과를 llm_text로 저장 후 Qdrant 텍스트 벡터로 임베딩 3. 최종적으로 RAG 검색 품질(텍스트 의미 매칭) 향상에 기여
채택 사유	• 약 3,500건 규모(실측 약 3,378건)의 장소 데이터에 대해 비용 효율적으로 설명문 생성 가능 • 상위 모델 대비 빠른 처리 속도로 대량 배치 생성에 유리 • 프롬프트 제어를 통해 필수 필드 누락 방지, 검색 친화 문장 생성 가능 • 체크포인트팅(기처리 ID 스킵) 방식으로 대량 배치 처리 안정성 확보