

SK네트웍스 Family AI과정 21기

모델링 및 평가 수집된 데이터 및 전처리 문서

산출물 단계	모델링 및 평가
평가 산출물	수집된 데이터 및 전처리 문서
제출 일자	2026.03.08.
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN21-FINAL-2Team.git
작성 팀원	전우영

목차

1. 프로젝트 개요
2. 수집 데이터 개요
 - 2.1. 한국관광공사 TourAPI 데이터
 - 2.2. 팝업스토어 플랫폼 POPPLY 크롤링 데이터
3. 수집 데이터 상세
4. 전처리 상세

1. 프로젝트 개요

Triver(트리버)는 외국인 관광객들의 국내 여행 전 과정을 책임지는 LLM 기반 AI 여행 에이전트.

- **초개인화 추천 엔진:** 사용자의 명시적인 요청뿐만 아니라 이미지, 과거 취향, 실시간 상황을 복합적으로 분석하여 사용자에게 딱 맞는 장소를 추천
- **장소 추천부터 코스 계획:** 개별 장소 반환에서 나아가 사용자의 위치, 이동 수단 등을 종합적으로 분석하여 이동 효율을 극대화하는 알고리즘 기반 동선 설계
- **여행 계획과 예약 관리:** 여행지 검색부터 여행 상품 예약까지 가능한 채팅 인터페이스, 여러 플랫폼에서 예약한 다양한 바우처를 저장해둘 수 있는 나만의 여행 지갑 제공

2. 수집 데이터 개요

2.1. 수집데이터 종류

공공 관광 자산과 같은 정적 데이터 확보와 팝업 및 핫플레이스 등의 최신 트렌드 반영이 필요한 동적 데이터 수집을 결합한 하이브리드 수집 방식을 채택함.

2.2. 수집 데이터 종류

2.2.1. 한국관광공사 '대한민국 구석구석' (TourAPI)

관광지, 문화시설, 음식점, 정부 기관에서 구축한 API로 장소명, 주소, 이용 시간 등 기초 정보의 정확도가 높고, 국문 데이터와 일대일 매칭이 가능한 다국어(영·중·일 등) 데이터를 안정적으로 제공받을 수 있음. 모든 장소에 정밀한 mapx, mapy 좌표가 포함되어 있어, 최적 경로 알고리즘을 구현하는 데 필요한 속성 수집할 수 있음.

- **원시 데이터 형태** : XML / JSON (공공데이터포털 Open API 응답 데이터)
- **수집 방식** : REST API 연동 (HTTP 프로토콜 기반 요청)
- **사용 API**: [areaBasedList2](#), [detailIntro](#), [detailInfo](#) 등
- **수집 대상**: 대한민국 구석구석 내 관광 정보 (관광지, 문화시설, 여행코스, 숙박 등)
- **주요 필드**: 장소명, 위치(주소 및 좌표), 카테고리, 이미지, 운영시간 등
- **저장 포맷**: JSONL

데이터명	데이터 성격	활용 기능
관광지	정적	이미지 기반 '스냅 탐색' 추천
문화시설	정적	날씨 등을 고려한 실내 관광지 추천
축제공연행사	동적	방문 날짜 기준 일정 자동 구성
여행코스	반정적	검증된 루트 기반의 일정 제안
레포트	정적	활동적 성향의 사용자용 액티비티 추천
숙박	반정적	최적 동선 내 숙소 추천 및 연결
음식점	반정적	위치 기반 식당 추천

2.2.2. 팝업스토어 플랫폼 'POPPLY' 크롤링

공공 데이터가 담아내지 못하는 핫플레이스 정보 제공을 위한 데이터를 수집함. 그 중 최근 외국인 관광객들의 필수 여행 코스로 자리잡은 팝업스토어를 트렌드 데이터로 사용함. 장소 정보에 비해 비교적 잦은 변동이 있는 데이터로, 사용자 검색 시점에 방문 가능한 이벤트 정보를 수집하여 서비스의 동적 가치를 높임. 일반적인 관광지 외에도 특정 브랜드나 테마에 민감한 사용자(MZ세대 외국인 등)를 위한 개인화 추천 엔진의 '트렌드 가중치' 데이터로 활용하고자 함.

- **원시 데이터 형태** : HTML / 공개 웹 페이지 (POPPLY 서비스 내 비정형 텍스트 및 이미지)
- **수집 방식** : 웹 크롤링 (Selenium 및 BeautifulSoup 활용)
- **사용 API**: [Search API \(Blog\)](#)
- **수집 대상**: 각 장소별 실방문자 후기 및 로컬 이용자 리뷰
- **주요 필드**: 블로그 포스트 제목, 본문 요약, 포스트 링크, 발행 일자 등
- **저장 포맷**: JSONL

구분	데이터명	데이터 성격
P001	팝업스토어	동적

3. 수집 데이터 상세

3.1. 한국관광공사 '대한민국 구석구석' (TourAPI)

수집된 공공 데이터는 DB 저장을 위해 다음과 같은 표준 스키마로 변환.

필드명	타입	예시값
contentid	string	"126508"
contenttypeid	string	"관광지"
title	string	"경복궁"
addr	string	"서울 종로구 사직로 161"
mapx	float	"126.976929"
mapy	float	"37.579617"
overview	string	"조선의 법궁..."

- 주요 필드

- contentid : 장소 고유 ID
- title : 장소명
- image : 장소 사진
- usetime : 운영시간
- mapx / mapy : 장소의 경도 / 위도

- 추출 데이터 샘플

```
{
  "contentid": "2733967",
  "title": "가회동성당",
  "contenttypeid": "관광지",
  "image": "http://tong.visitkorea.or.kr/...",
  "usetime": "06:00~18:00",
  "addr": "서울특별시 종로구 북촌로 57",
  "mapx": 126.9846,
  "mapy": 37.5820
}
```

3.2. 팝업스토어 플랫폼 'POPPLY' 크롤링

필드명	타입	설명
url	string	고유 식별자 (중복 제거 기준)
name		팝업스토어 및 이벤트 명
schedule		운영 기간(예: 2026.01.09 ~ 03.31)
location		상세 위치 정보
introduction		상세 소개 및 테마 (임베딩 대상)
options		주차 등 부가 옵션 정보

- 주요 필드

- **contentid**: 장소 고유 ID
- **title**: 장소명
- **image**: 장소 사진
- **usetime**: 운영시간
- **mapx / mapy**: 장소의 경도 / 위도

- 추출 데이터 샘플

```
{
  "url": "https://www.popply.co.kr/popup/4407",
  "name": "모무 롯데백화점 잠실 팝업",
  "schedule": "2026-02-06T00:00:00 ~ 2026-03-05T00:00:00",
  "location": "서울 송파구 올림픽로 240",
  "hours": "10:30 ~ 20:00",
  "introduction": "< 모무 롯데백화점 잠실 팝업>\n\n잠실에서 모무 클리커를\n만날 수 있는 특별한 기회가 찾아왔어요!\n\n",
  "thumbnail": "https://d8nffddmkwqeq.cloudfront.net/store/5d444fcf%2C9ebc%2C4d7f%2Cb0e5%2C14bb",
  "parking": "주차 가능",
  "fee": "무료",
  "pet": "Unknown",
  "kids": "Unknown",
  "food_ban": "Unknown",
  "adult_only": "Unknown",
  "wifi": "Unknown",
  "photo": "Unknown"
},
```

4. 전처리 상세

4.1. 전처리 파이프라인

1) 데이터 수집 단계

- **API 데이터**: 요청 파라미터를 통해 필요한 정보(관광지, 위치 등)를 호출
- **크롤링 데이터**: 웹 사이트에서 팝업스토어 상세 정보 추출

2) 소스별 개별 전처리 단계

- **API 데이터**: 복잡한 JSON 계층을 평탄화(Flattening)하고, 불필요한 데이터 제거
- **크롤링 데이터**: 이모지, 특수문자, \n 등을 제거하고 "Unknown" 값 처리

3) 데이터 표준화 및 통합

- **주소 표준화**: 각기 다른 주소 형식 통일
- **카테고리 매핑**: 관광지 타입과 팝업 카테고리를 서비스 내부 분류 체계에 맞게 매핑

4) 최종 저장

- **VectorDB(Qdrant)**: 정제된 **llm_text**를 임베딩하여 유사도 검색용으로 저장

4.2. 세부 전처리 내용

4.2.1. 한국관광공사 Tour API 데이터

● 전처리 과정

단계	구분	전처리 내용
1	API 필터링 호출	● 데이터 파싱 및 정규화: API 응답 데이터의 불필요한 Depth를 제거하고 평탄화하여 데이터 모델을 정규화 ● 필드 매핑 및 필터링: Open API의 명세서를 기반으로 서비스 목적에 맞는 주요 파라미터를 선별하고, 필드 매핑 작업을 수행
2	스키마 개편	● 데이터 스키마 개편: 키값을 직관적으로 정리. 수집한 데이터를 DB에 저장하거나 API로 다시 내보내기 적합한 구조로 개편 또한 진행
3	결측치 및 텍스트 전처리	● 결측치 키 삭제: value값이 null이거나, 공란일 경우 키를 삭제 ● 불필요한 텍스트 제거: 2차 전처리 후에도 결측치가 있거나, 의미 전달에 방해가 되는 문장 부호, 특수 기호, HTML 태그 등이 존재하는 경우 제거
4	LLM 텍스트 보강	● 임베딩 형태로 전환: VectorDB 임베딩을 위한 형태로 변환. LLM Text와 Payload에 입력될 metadata를 구분하고, 기존의 정보와 LLM 보강 데이터를 기반으로 LLM Text를 문서 형태로 전환. ● 정서적 데이터 추가: VectorDB에 임베딩할 데이터를 텍스트 형태로 반환, 장소에 대한 분위기나 설명을 담은 데이터를 LLM을 활용해 보강

● 데이터 형태 변화

원시 데이터	1차 전처리
--------	--------

<pre>{ "response": { "header": { "resultCode": "0000", "resultMsg": "OK" }, "body": { "items": { "item": [{ "contentid": "126128", "contenttypeid": "12", "heritage1": "0", "heritage2": "0", "infocenter": "국립중앙도서관 053-662-2867", "opendate": "", "restdate": "연중무휴", "expguide": "", "expagerange": "", "accomcount": "", "useseason": "", "usetime": "상시 개방", "parking": "가능", "chkbaby carriage": "없음", "chkipet": "", "chkdirtcard": "없음" }] }, "numOfRows": 1, "pageNo": 1, "totalCount": 1 } } }</pre>	<pre>1 { 2 "contentid": "2733967", 3 "title": "가회동성당", 4 "contenttypeid": "관광지", 5 "firstimage": "http://tong.visitkorea.or.kr/cms/resource/09/ 6 "usetime": "[주일미사]
\n- 새벽미사 06:00
\n- 교중미사 11:00", 7 "restdate": "매주 월요일", 8 "parking": "가능", 9 "addr1": "서울특별시 종로구 북촌로 57 (가회동)", 10 "addr2": "", 11 "mapx": "126.9846616856", 12 "mapy": "37.5820858828", 13 "areacode": "1", 14 "cat1": "A02", 15 "cat2": "A0201", 16 "cat3": "A02010900", 17 "lclsSystem1": "H5", 18 "lclsSystem2": "H503", 19 "lclsSystem3": "H5030200", 20 "lDongRegnCd": "11", 21 "lDongSignuCd": "110", 22 "contenttypeid_code": "12" 23 }</pre>
2차 전처리 후	최종 데이터(임베딩 text)
<pre>1 { 2 "contentid": "2733967", 3 "title": "가회동성당", 4 "contenttypeid": "관광지", 5 "image": "http://tong.visitkorea.or.kr/c 6 "usetime": "[주일미사]
\n- 새벽미사 06:00 7 "restdate": "매주 월요일", 8 "parking": "가능", 9 "addr": "서울특별시 종로구 북촌로 57 (가회동)", 10 "mapy": "37.5820858828", 11 "mapx": "126.9846616856", 12 "tel": "", 13 "contenttypeid_code": "12" 14 }</pre>	"서울특별시 종로구 북촌로에 위치한 가회동성당은 아름다운 건물이 성당은 주일마다 새벽미사(06:00), 교중미사(11:00), 토요일 저녁에는 특별한 주일미사도 열립니다. 평일에는 월요일을 제외한 화요일(19:00), 수요일(10:00), 매월 첫 번째 일요일에는 유아세례가 이루어집니다. 주차 가능하여 차량으로 방문하기에도 편리하며, 매주 월요일 가회동성당은 그 자체로도 아름다움을 지니고 있지만, 신앙의 공동체로서의 따뜻한 분위기와 함께 방문객들에게 특별한

4.2.2. 팸플리 웹 크롤링 데이터

● 전처리 계획

단계	구분	전처리 내용
1	결측치 표준화 및 처리	● Unknown 제거: TourAPI 스키마에 맞춰 생성했던 pet, kids, wifi 키의 값들이 "Unknown"으로 채워짐. 이를 그대로 두면 모델이 "Unknown"이라는 단어 자체를 학습하게 되므로, 해당 키를 완전히 제외
2	텍스트 노이즈 및 이미지 제거	● 이모지 및 특수기호: 검색 엔진(예: Elasticsearch, Qdrant)에서 인덱싱 효율을 떨어뜨릴 수 있으므로 정규표현식을 통해 제거. ● 줄바꿈 기호: \n은 공백으로 치환해 문장이 끊기지 않고 하나의 텍스트 흐름(Stream)을 갖게 함.
3	날짜 및 시간 데이터 파싱	● 데이터 타입 변환: "2026-01-09T00:00:00"와 같은 문자열은 단순 텍스트가 아닌 ISO 8601 형식의 날짜 객체로 변환
4	위치값 추가	● x, y 좌표값 추가: API 데이터와 달리 위치 좌표 정보가 없으므로 주소를 기반 Geo코드 사용하여 위치값 업데이트

5	LLM 텍스트 보강	임베딩 형태로 전환: VectorDB 임베딩을 위한 형태로 변환. LLM Text와 Payload에 입력될 metadata를 구분하고, 기존의 정보와 LLM 보강 데이터를 기반으로 LLM Text를 문서 형태로 전환. 정서적 데이터 추가: VectorDB에 임베딩할 데이터를 텍스트 형태로 반환, 장소에 대한 분위기나 설명을 담은 데이터를 LLM을 활용해 보강
---	------------	--

● 데이터 형태 변화

원시 데이터	1차 전처리
<pre>{ "url": "https://www.poppy.co.kr/popup/4265", "name": "미니소 X 미미월드 팝업스토어", "schedule": "2026-01-09T00:00:00 ~ 2026-03-31T00:00:00", "location": "서울 강서구 하늘길 38", "hours": "10:30 ~ 22:00", "introduction": "최대 규모 팝업스토어 오픈! 미니소 X 미미월드 팝업스토어", "thumbnail": "https://d8nffddmkwqeq.cloudfront.net/store/78", "parking": "주차 가능", "fee": "무료", "pet": "Unknown", "kids": "Unknown", "food_ban": "Unknown", "adult_only": "Unknown", "wifi": "Unknown", "photo": "Unknown" },</pre>	<pre>{ "contentid": "9000002", "title": "그린치 팝업스토어", "contenttypeid": "팝업스토어", "contenttypeid_code": "99", "image": "https://d8nffddmkwqeq.cloudfront.net/store/9c4806e2%2", "addr": "서울 용산구 한강대로23길 55", "usetime": "10:30 ~ 22:00", "start_date": "2026-02-20", "end_date": "2026-03-05", "restdate": "", "introduction": "실용성에 키치를 더한! 그린치 팝업스토어", "parking": "주차 가능", "fee": "무료" },</pre>
2차 전처리	3, 4차 전처리
<pre>{ "contentid": "9000002", "title": "그린치 팝업스토어", "contenttypeid": "팝업스토어", "contenttypeid_code": "99", "image": "https://d8nffddmkwqeq.cloudfront.net/store/9c4806e2%2", "addr": "서울 용산구 한강대로23길 55", "usetime": "10:30 ~ 22:00", "start_date": "2026-02-20", "end_date": "2026-03-05", "restdate": "", "introduction": "실용성에 키치를 더한! 그린치 팝업스토어가 용산", "parking": "주차 가능", "fee": "무료" },</pre>	<pre>{ "contentid": "9000002", "title": "그린치 팝업스토어", "contenttypeid": "팝업스토어", "contenttypeid_code": "99", "image": "https://d8nffddmkwqeq.cloudfront.net/store/9c4806e2%2", "addr": "서울 용산구 한강대로23길 55", "usetime": "10:30 ~ 22:00", "start_date": "2026-02-20", "end_date": "2026-03-05", "restdate": "", "introduction": "실용성에 키치를 더한! 그린치 팝업스토어가 용산 아이파크몰에", "parking": "주차 가능", "fee": "무료", "mapy": "37.5297718", "mapx": "126.9647415", "road_address": "서울특별시 용산구 한강대로23길 55 용산역", "old_address": "서울특별시 용산구 한강로3가 40-999 용산역" },</pre>
최종 데이터(임베딩 될 text)	
"서울 송파구 올림픽로 240에 위치한 롯데백화점 잠실점에서 모두 클릭! 2026년 2월 6일부터 3월 5일까지 운영되며, 월요일부터 목요일은 오전 10시 30분부터 저녁 8시까지, 금요일부터 일요일은 저녁 8시 30분까지 방문하실 수 있습니다. 입장료는 무료로, 주차 공간도 마련되어 있어 편리하게 이용 가능합니다. 이번 팝업스토어에서는 두쫂큐, 딸기 두쫂큐, 초코 마들렌 등 세 가지 매 사진으로만 보던 모두 클릭커를 직접 경험하고, 특별한 맛과 재미를 느껴. 일상 속 소소한 즐거움을 찾는 여러분을 기다립니다."	

