

SK네트웍스 Family AI과정 21기

모델링 및 평가 테스트 계획 및 결과 보고서

산출물 단계	모델링 및 평가
평가 산출물	테스트 계획 및 결과 보고서
제출 일자	2026.03.08.
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN21-FINAL-2Team.git
작성 팀원	김가람, 박민정, 전우영

목차

1. 테스트 개요 및 목적
2. 테스트 시나리오 및 방법
 - 2.1. RAG 테스트 시나리오
 - 2.2. 테스트 처리 흐름
3. 테스트 환경
4. RAG 성능 최적화 트래킹
 - 4.1. 단계별 최적화 적용 내역
5. RAG 파이프라인 모델링 평가 (3-Stage)
 - 5.1. Stage 1: 검색(Retrieval) 평가
 - 5.2. Stage 2: 추천(Recommendation) 평가
 - 5.3. Stage 3: 생성(Generation) 평가
6. 종합 평가
 - 6.1. 성능 평가 결과 요약
 - 6.2. 한계점 및 향후 개선 계획
 - 6.3. 결론

1. 테스트 개요 및 목적

본 테스트는 여행 추천 챗봇의 RAG 파이프라인에서 검색 정확도와 답변 생성의 신뢰성을 검증하기 위해 수행되었다. 초기 모델의 응답 지연 문제를 해결하기 위한 단계별 최적화 과정을 트래킹하고, 3-Stage(검색→추천→생성) 평가를 통해 실사용 가능성을 입증하는 데 목적이 있음.

2. 테스트 시나리오 및 방법

2.1. RAG 테스트 시나리오

실제 여행 추천 상담 상황을 가정한 대표 질의 21가지를 선정해 반복 실행

사용자의 input이 한국어가 아닌 경우에도 답변이 가능한지 확인.

질의 샘플	기대응답 샘플
한남대로20길에 위치한 소설한남 음식점은 어떤 매력을 가지고 있으며, 방문할 때 어떤 점을 고려해야 할까요?	소설한남은 서울특별시 용산구 한남대로20길 21-18에 위치한 현대적인 감각이 돋보이는 음식점으로, 맛있는 요리와 아늑한 분위기를 동시에 제공합니다. 이곳은 한남동의 매력적인 거리에서 쉽게 찾아갈 수 있으며, 정교하게 준비된 메뉴는 미식가들의 입맛을 사로잡습니다. 소설한남은 서울의 중심에서 특별한 미식 경험을 제공하며, 친구나 가족과 함께 소중한 시간을 보내기에 안성맞춤입니다. 또한, 이곳의 위치는 교통이 편리하여 방문하기 용이하며, 주변의 다양한 명소와 함께 즐길 수 있는 최적의 장소입니다. 특별한 순간을 놓치지 않도록 소설한남을 방문해 보시기 바랍니다.
What are the key features and visitor experiences offered at 도산안창호기념관 and 화랑대 철도공원, and how do they cater to families?	도산안창호기념관은 서울특별시 강남구에 위치하며, 한국의 독립운동가 안창호를 기리기 위해 설립된 문화시설입니다. 이곳은 현대적인 전시관으로, 방문객들에게 안창호의 철학과 독립운동의 역사적 맥락을 생생하게 전달합니다. 기념관은 접근성이 뛰어나며, 아름다운 경관과 조화를 이루고 있어 가족 단위 방문객들에게도 적합한 다양한 전시와 프로그램이 준비되어 있습니다. 주차 공간도 마련되어 있어 차량으로 방문하기에도 편리합니다. 반면, 화랑대 철도공원은 서울특별시 노원구에 위치하고 있으며, 상시 개방되어 있어 언제든지 방문할 수 있는 매력적인 관광지입니다. 이곳은 철도와 관련된 다양한 전시물과 함께 아름다운 자연을 즐길 수 있는 공간으로, 가족 단위 방문객들에게 특히 인기가 높습니다. 주차가 가능하여 차량으로의 접근이 용이하며, 반려동물과 함께하는 방문도 가능하지만 일부 구역에서는 동반이 제한됩니다. 이러한 규정을 준수하면 모든 연령과 함께 즐거운 시간을 보낼 수 있습니다. 두 장소 모두 가족들이 함께 역사와 자연을 체험하며 소중한 추억을 만들 수 있는 특별한 경험을 제공합니다.

2.2. 테스트 처리 흐름

1. LangGraph Intent 노드를 통한 질의 분기 (planner/executor_general/retriever)
2. Qdrant 벡터 검색 + BM25 하이브리드 검색
3. CrossEncoder(bge-reranker-base) 리랭킹

4. LLM(gpt-4o-mini)을 통한 여행 추천 답변 생성
5. End-to-End 응답 시간 측정
6. 검색 정확도 및 생성 품질 평가 (RAGAS)

3. 테스트 환경

구분	버전/상세
OS	macOS
Python	3.13+
LLM	OpenAI gpt-4o-mini
Embedding (Text)	BAAI/bge-m3 (1024-dim)
Embedding (Image)	CLIP-ViT-L-14 (768-dim)
Reranker	BAAI/bge-reranker-base (CrossEncoder)
Vector DB	Qdrant (places / photos 컬렉션)
RAG 평가 도구	RAGAS (gpt-4o-mini + text-embedding-3-small)
테스트 프레임워크	pytest, pytest-asyncio

4. RAG 성능 최적화 트래킹

4.1. 단계별 최적화 적용 내역

step	단계	내용
1	[Baseline] 초기 파이프라인 구성	- 적용 내용: RAG 기본 파이프라인 구성 및 전체 필드 생성 지시 - 문제점: 입력 컨텍스트 및 출력 토큰 수 과다, 실시간 요구사항에 부적합한 지연 발생
2	[프롬프트 경량화] 출력 포맷 개선	- 적용 내용: LLM이 핵심 요약문 생성에만 집중하도록 프롬프트 구조 축소, response_format={"type":"json_object"} 적용 - 효과: 출력 구조 오류 감소, 요약 생성 시간 점진적 감소
3	[파라미터 튜닝] LLM 입력 축소	- 적용 내용: Retrieval top_k 최적화 및 검색 로직 효율화, 문서 길이 제한 - 효과: 입력 토큰 수 감소, 생성 시간 단축
4	[구조 최적화] 병목 제거	- 적용 내용: 캐시 도입 및 생성 병목 구간 제거 - 효과: 캐시 적용 시 LLM 호출 제거, End-to-End 응답 시간 대폭 개선

5. RAG 파이프라인 모델링 평가

5.1. Stage 1: 검색(Retrieval) 평가

검색 시스템이 관련 문서를 얼마나 정확하게 찾아오는지 평가

- Precision@K : 상위 K개 검색 결과 중 관련 문서 비율 (정밀도)
- Recall@K : 전체 관련 문서 중 상위 K개에 포함된 비율 (재현율)
- MRR@K : 첫 번째 관련 문서의 역순위 평균
- nDCG@K : 정규화된 할인 누적 이득 (순위 품질)
- MAP@K : 평균 정밀도

First-stage			
지표	1차	2차	변화
Precision@K	0.2381	0.1810	하락
Recall@K	0.8095	0.7619	하락
MAP@K	0.6782	0.6111	하락
Rerank-stage			
지표	1차	2차	변화
MRR@K	0.6786	0.6627	소폭 하락
nDCG@K	0.7156	0.6834	하락
MAP@K	0.6782	0.6548	하락
delta_nDCG@K	0.6782	0.6111	상승
delta_MRR@k	0.0000	0.0516	상승

5.2. Stage 2: 추천(Recommendation) 평가

최종 추천된 장소의 정확도와 다양성 평가

- Precision@N : 추천 장소 중 정답 비율
- Recall@N : 정답 장소 중 추천된 비율
- nDCG@N : 추천 순위 품질
- ILD@N : 추천 목록 내 다양성 (Intra-list Diversity, 0=동일, 1=다양)
- Category Coverage : 카테고리(관광지/음식점 등) 분포 커버리지
- District Diversity : 지역 분포 다양성
- Entity Existence Rate : 추천 장소가 DB에 실존하는 비율

지표	1차	2차	변화
Precision@N	0.7778	0.5794	하락
Recall@N	0.7857	0.7381	하락
nDCG@N	0.7911	0.6908	하락
ILD@N	0.0794	0.2857	상승
Category Coverage	0.6825	0.8095	상승
District Diversity	0.7937	0.7302	소폭 하락

5.3. Stage 3: 생성(Generation) 평가

LLM 답변의 품질을 RAGAS 메트릭으로 평가

(gpt-4o-mini + text-embedding-3-small 기반)

- Faithfulness : 답변이 검색된 문서에 근거하는 정도 (환각 방지)
- Answer Relevancy : 답변이 질문에 적합한 정도
- Context Precision : 관련 문맥이 상위에 위치하는 정도
- Context Recall : 정답에 필요한 정보가 문맥에 포함된 정도

지표	1차	2차	변화
Faithfulness	0.1573	0.2177	상승
Answer Relevancy	0.5385	0.5324	소폭 하락
Context Precision	0.0000	0.0000	동일
Context Recall	0.1417	0.4375	대폭 상승

5.4. 시나리오 평가

LLM 답변 품질을 RAGAS 메트릭으로 평가 (gpt-4o-mini + text-embedding-3-small 기반)

[시나리오 테스트 결과 전체 \(스프레드 시트\)](#)

1	한남대로20길에 위치한 소설한남 음식점은 어떤 매력을 가지고 있으며, 방문할 때 어떤 점을 고려해야 할까요?	
	기대	소설한남은 서울특별시 용산구 한남대로20길 21-18에 위치한 현대적인 감각이 돋보이는 음식점으로, 맛있는 요리와 아늑한 분위기를 동시에 제공합니다. 이곳은 한남동의 매력적인 거리에서 쉽게 찾아갈 수 있으며, 정교하게 준비된 메뉴는 미식가들의 입맛을 사로잡습니다. 소설한남은 서울의 중심에서 특별한 미식 경험을 제공하며, 친구나 가족과 함께 소중한 시간을 보내기에 안성맞춤입니다. 또한, 이곳의 위치는 교통이 편리하여 방문하기 용이하며, 주변의 다양한 명소와 함께 즐길 수 있는 최적의 장소입니다. 특별한 순간을 놓치지 않도록 소설한남을 방문해 보시기 바랍니다.

		소설한남은 한남대로20길에 위치한 멋진 음식점으로, 현대적인 감각과 전통적인 요소가 잘 어우러진 공간입니다. 이곳은 아늑한 분위기와 함께 세련된 인테리어가 매력적이며, 친구나 연인과의 특별한 식사에 적합한 장소입니다. 특히, 다양한 한식 메뉴가 준비되어 있어 한국의 맛을 깊이 있게 경험할 수 있습니다. 소설한남은 신선한 재료를 사용하여 정성스럽게 만든 요리들로 유명합니다. 특히, 그들의 대표 메뉴는 특유의 깊은 맛과 풍부한 향이 일품이어서, 한 번 맛보면 다시 찾고 싶어지는 매력이 있습니다. 또한, 친절한 서비스가 더해져 편안한 식사 경험을 제공합니다. 방문하실 때는 미리 예약을 고려하시는 것이 좋습니다. 특히 주말이나 저녁 시간대에는 손님이 많아 대기시간이 길어질 수 있기 때문입니다. 그리고 메뉴에 대한 설명을 잘 듣고, 추천 메뉴를 시도해보시는 것도 좋은 경험이 될 것입니다. 소설한남의 매력을 직접 느껴보시길 추천합니다. 자세한 위치는 [여기](https://map.naver.com/v5/search/%EC%86%8C%EC%84%A4%ED%95%9C%EB%82%A8)에서 확인하실 수 있습니다.
2	What are the key features and visitor experiences offered at 도산안창호기념관 and 화랑대 철도공원, and how do they cater to families?	
	기대	도산안창호기념관은 서울특별시 강남구에 위치하며, 한국의 독립운동가 안창호를 기리기 위해 설립된 문화시설입니다. 이곳은 현대적인 전시관으로, 방문객들에게 안창호의 철학과 독립운동의 역사적 맥락을 생생하게 전달합니다. 기념관은 접근성이 뛰어나며, 아름다운 경관과 조화를 이루고 있어 가족 단위 방문객들에게도 적합한 다양한 전시와 프로그램이 준비되어 있습니다. 주차 공간도 마련되어 있어 차량으로 방문하기에도 편리합니다. 반면, 화랑대 철도공원은 서울특별시 노원구에 위치하고 있으며, 상시 개방되어 있어 언제든지 방문할 수 있는 매력적인 관광지입니다. 이곳은 철도와 관련된 다양한 전시물과 함께 아름다운 자연을 즐길 수 있는 공간으로, 가족 단위 방문객들에게 특히 인기가 높습니다. 주차가 가능하여 차량으로의 접근이 용이하며, 반려동물과 함께하는 방문도 가능하지만 일부 구역에서는 동반이 제한됩니다. 이러한 규정을 준수하면 모든 견종과 함께 즐거운 시간을 보낼 수 있습니다. 두 장소 모두 가족들이 함께 역사와 자연을 체험하며 소중한 추억을 만들 수 있는 특별한 경험을 제공합니다.
	실제	서울의 문화시설 중에서 특별한 경험을 제공하는 두 곳을 추천드리겠습니다. 첫 번째로는 [도산안창호기념관](https://map.naver.com/v5/search/%EB%8F%84%EC%82%B0%EC%95%88%EC%B0%BD%ED%98%B8%EA%B8%B0%EB%85%90%EA%B4%80)입니다. 이곳은 대한민국의 독립운동가인 안창호 선생의 업적을 기리기 위해 세워진 공간으로, 역사에 대한 깊은 이해를 돕는 다양한 전시와 자료들이 마련되어 있습니다. 특히 가족 단위 방문객들에게는 교육적인 요소가 풍부하여, 자녀들에게 역사적 인물을 알리고 그들의 가치관을 배우는 데 큰 도움이 될 것입니다. 기념관 주변은 조용하고 아늑한 분위기여서 가족이 함께 산책하며 이야기를 나누기에도 좋습니다. 두 번째 추천 장소는 화랑대 철도공원입니다. 이곳은 철도와 관련된 다양한 전시와 체험을 제공하며, 아이들이 기차를 가까이에서 보고 직접 조작해볼 수 있는 기회를

	제공합니다. 가족 단위 방문객들은 아이들과 함께 다양한 놀이시설과 넓은 공간에서 여유롭게 시간을 보낼 수 있어, 즐거운 하루를 보낼 수 있는 최적의 장소입니다. 또한, 공원 내에서는 피크닉을 즐길 수 있는 공간도 마련되어 있어 가족이 함께 소중한 추억을 만들기에 적합합니다. 이 두 곳은 각각 역사와 교육, 놀이와 체험을 통해 가족 모두가 즐겁고 의미 있는 시간을 보낼 수 있도록 잘 구성되어 있습니다. 서울에서의 특별한 문화 체험을 원하신다면 꼭 방문해 보시기를 추천드립니다.
--	---

6. 종합 평가

6.1. 성능 평가 결과 요약

- **Retrieval & Rerank 성과 (BM25/Reranker 효과)**
 - 이전에는 Reranker의 개선 효과가 거의 없었으나, 현재 **확실한 성능 향상** 확인
 - Reranker가 1단계 검색 결과 중 사용자의 의도에 더 적합한 장소를 상위권으로 끌어올리고 있으며, 상위권 순위 보장 능력(MRR)에서 더 큰 효과를 보임
 - **delta_ndcg@k: +0.0331** (약 3.3% 향상)
 - **delta_mrr@k: +0.0516** (약 5.2% 향상)
- **Recommendation 성과 (최종 추천 품질)**
 - 검색된 후보들 중 관련 있는 장소를 최종 추천 리스트에 포함시키는 능력이 양호
 - 10개 중 7개 이상의 관련 장소를 놓치지 않고 추천하고 있음
 - **Recall@N (5개 추천 기준): 0.738**
 - **Precision@N: 0.579**
 - **Entity Existence Rate: 1.0** (추천된 모든 ID가 실제 DB에 존재함)
- **Generation 성과 (답변 생성 품질)**
 - 현재 생성 모델이 제공된 컨텍스트(검색 결과)를 충분히 활용하지 못하거나, 컨텍스트에 없는 내용을 답변하는 경향(Hallucination) 발견
 - 답변 생성 프롬프트 보강 및 컨텍스트 주입 방식 개선 필요성 존재
 - **Faithfulness (근거성): 0.1839** (낮음)
 - **Answer Relevancy (질문 관련성): 0.5398**

6.2. 한계점 및 향후 개선 계획

- **프롬프트 엔지니어링 강화** : 생성된 답변이 검색된 문서에 기반하는 정도를 나타내는 Faithfulness(근거성) 점수가 0.1839로 매우 낮음. "반드시 제공된 정보 내에서만 답변하라"는 지시를 명시하고, 답변의 출처(근거 문장)를 함께 표기하는 등 프롬프트 보강 필요
- **하이브리드 검색 가중치 최적화**: 사용자의 의도와 맞지 않는 장소가 추천 리스트에 다수 포함되고 있어, 현재 적용된 BM25(키워드)와 벡터 검색 간의 가중치를 재조정하여 검색 결과의 정확도를 높여야 함.
- **리랭커(Reranker) 성능 고도화**: 리랭커가 상위권 순위 보장에는 효과를 보이고 있으나

전체적인 정밀도를 떨어뜨리고 있으므로, 리랭커의 임계값(Threshold)을 설정해 관련성이 낮은 항목을 사전에 필터링하는 로직이 필요

- **칭킹 전략 수정 및 쿼리 확장:** 관련 문맥이 검색 결과의 상위에 위치하는 정도를 평가하는 Context Precision 점수가 0.0000으로 측정됨. 현재 문서의 분할 단위가 너무 크거나 작지 않은지 검토하고, 검색 엔진이 핵심 의미를 더 잘 포착할 수 있도록 데이터 전처리 단계 개선. 사용자의 모호한 질문을 검색에 적합한 형태로 확장(LLM 활용)하여, 검색 엔진이 더 관련성 높은 문서를 상단에 배치할 수 있도록 유도